VITMO

Разработка системы онлайнантифрода для сервиса Новостей

Докладчик: Гуммель Никита

Научный руководитель: Койнов Руслан

Компания: ООО "Дзен.Платформа"

Описание предметной области



Фрод – это любое действие, противоречащее правилам пользования платформой или совершенное ненастоящим пользователем, то есть роботом





Антифрод - комплекс мер, направленных на мониторинг и борьбу с фродом.

Одно из основных направлений антифрода - поиск фрода в событиях сервисов.

Исходный процесе



Выявление фрода в логах делится на два вида:



- Оффлайн-антифрод поиск фродовых пользователей.
- Онлайн-антифрод потоковая разметка событий логов на наличие фрода.

В августе 2022 года, платформы Дзен и Новости перешли от Яндекса к VK Group.

В связи с этим у сервиса Новости пропал доступ к онлайн-антифроду, который ранее совершался на стороне Яндекса.

Также сервис Новости начал пользоваться принятым в Дзене logfeller для сбора и поставки логов событий.

Цели и задачи







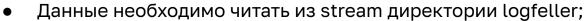
Цели: разработка системы онлайн-антифрода, поставляющая таблицы с добавлением колонки rules, содержащей идентификаторы правил, обнаруживших фрод в событии, с организацией директорий таблиц, соответствующей формату поставки logfeller.

Задачи:

- Применить правила онлайн-антифрода Дзена к логам сервиса Новостей
- Выявление требований к времени поставки таблиц и используемым вычислительным квотам
- Проектирование системы, выделение квоты и подготовка архитектуры данных
- Реализовать асинхронное исполнение графов вычислений

Функциональные требования







- Поставка таблиц должна осуществляться в том же формате, что и у logfeller;
- SLA поставки таблиц не более 4 часов;
- Настроены мониторинги времени поставки таблиц и работы отдельных компонентов;
- Должны быть настроены алерты об упавших процессах и задержке поставки таблиц;
- В поставляемых таблицах должна присутствовать колонка rules, содержащая идентификаторы правил, разметивших данное событие как фрод.

Нефункциональные требования



• Чтение должно происходить по батчам таблиц для асинхронной работы;



- Процессы должны быть независимы друг от друга с целью асинхронности выполнения различных компонентов системы;
- Процессы не должны работать одновременно с чувствительными данными во избежание нарушения консистентности данных;
- Все табличные данные должны хранить на YT;
- В процессе разработки необходимо использовать YQL, Nirvana, Hitman и Datalens
- Должна быть настроены разграничения доступов.

Описание технологий



Используемые технологии: YQL, Nirvana, YT, Hitman, Groovy, DataLens, TelegramApi.





Внутренние технологии:

- YQL (Yandex Query Language, SQL диалект от Яндекса с пакетом дополнительных библиотек Яндекса)
- YT (Yandex Tables, сервис распределенного хранения и обработки данных с поддержкой модели MapReduce, распределенной файловой системой и NoSQL key-value базой данных)
- Hitman (платформа для автоматизации запусков продакшн-процессов)
- DataLens (инструмент визуализации данных)

Нирвана -



облачная платформа для управления процессами, которые оформлены в виде ациклических графов.







Системная архитектура



Используемые технологии находятся в одном серверном окружении Яндекса.



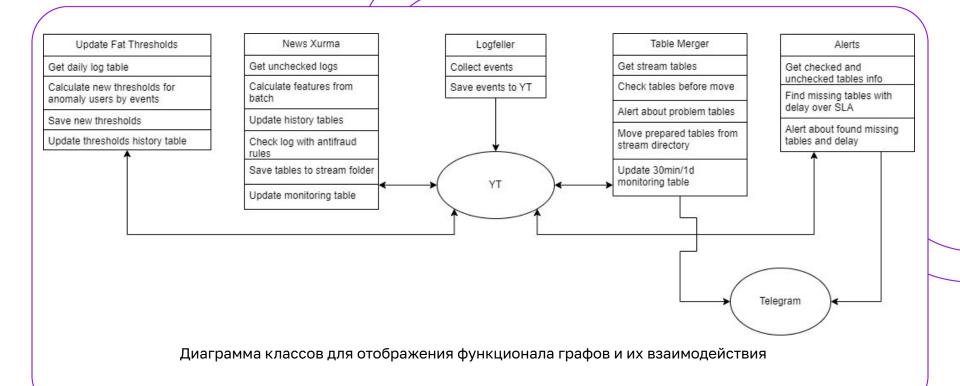


Используемые компоненты системы:

- Сервис Hitman для регулярного запуска Nirvana-графов, мониторинга всего проекта и отдельных процессов в нем
- Сервис Nirvana для составления графов исполнения
- Все табличные данные находятся в хранилище данных YT
- Запускаемые YQL-операции разбиваются на map-reduce операции на YT

Программная архитектура





Программная архитектура



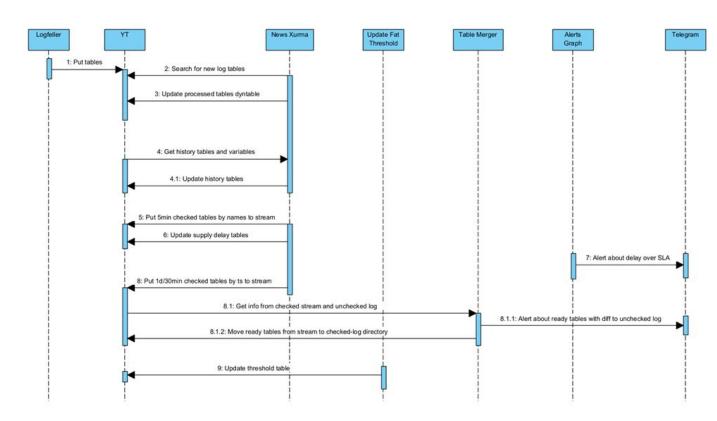
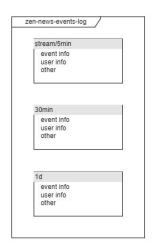
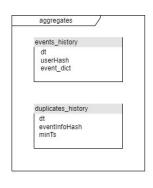


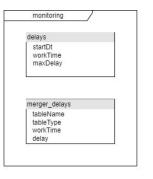
Диаграмма последовательности взаимодействия компонентов

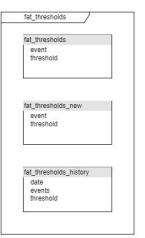
Используемые данные

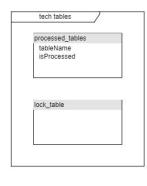


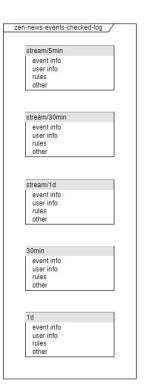








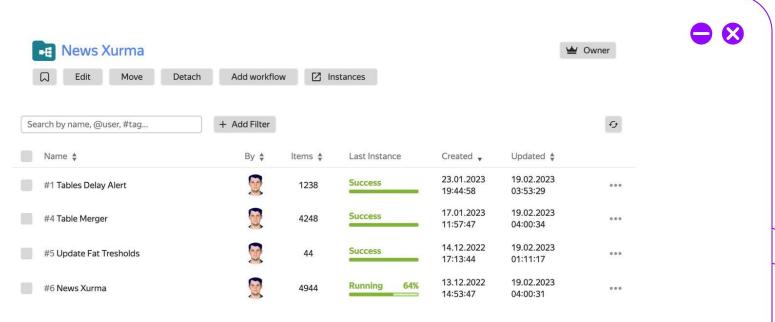




Визуализация используемых таблиц с разбиением по функциональным группам

Реализация





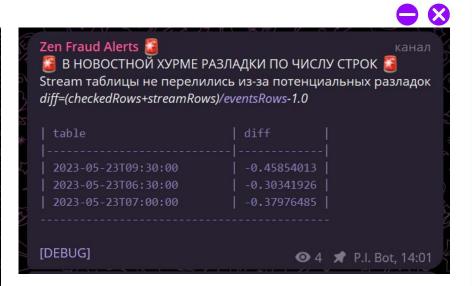
Реализованные графы в интерфейсе Nirvana

Алерты



Zen Fraud Alerts ॄ ☑ ЧТО-ТО СЛОМАЛОСЬ В НОВОСТНОЙ ХУРМЕ ॄ Поставка checked-log на arnold задерживается больше, чем на 4 час(a/ов))	
table	creation_time_utc
 30min/2023-02-28T18:00:00 30min/2023-02-28T19:00:00	 2023-02-28T16:05:49 2023-02-28T16:41:59
[DEBUG]	⊙ 4 P.I. Bot, 23:54
Прокомментировать	>

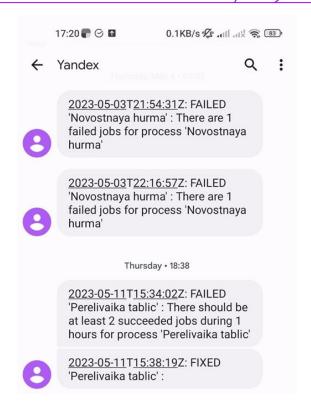
Алерт о задержке поставки таблиц



Алерт о задержке поставки событий в stream директорию

Алерты









Мониторинги поставки таблиц







Тестирование



Разработка данной системы с использованием выбранных технологий позволила сначала проверить все потенциальные проблемы с асинхронным исполнением.





сначала проверить все потенциальные проблемы с асинхронным исполнением. Система была протестирована с помощью ручного тестирования, качество системы оценивается с помощью грамотно настроенных алертов и мониторингов Hitman.

Результат



Поставляемые таблицы активно используются:



- В построени продуктовых метрик и дашбордов
- ML командой для обучения ранжирующих формул.
- В А/В-тестах для очистки данных от фрода
- Используется в команде антифрода для построения новых процессов

Спасибо за внимание!

ITSMOre than a UNIVERSITY